

Prédiction de la valeur foncière (*Données DVF 2019–2024*)

Sami Bensadok
Eloi Raad

Objectif :

Prédire la valeur d'un bien immobilier à partir des données issues de la base DVF (Demandes de Valeurs Foncières).

Données utilisées :

Tableaux de plusieurs dizaines de variables (colonnes) et de quelques millions de lignes.

```
Identifiant de document|Reference document|1 Articles CGI|2 Articles CGI|3 Articles CGI|4 Articles CGI|5 Articles CGI|No disposition|Date mutation|Natur
|||||000001|01/07/2019|Vente|244200,00|73||RUE|0958|COMMANDANT COUSTEAU|1000|BOURG-EN-BRESSE|01|53|CN|405|0|1|Maison||150|5|S||695
|||||000001|04/07/2019|Vente|195000,00|852||CHE|0170|DE LA CROIX ROSIER|1250|HAUTECOURT-ROMANECH|01|184|AM|237|0|1|Maison||94|4|AG||888
|||||000001|04/07/2019|Vente|195000,00|852||CHE|0170|DE LA CROIX ROSIER|1250|HAUTECOURT-ROMANECH|01|184|AM|237|0|1|Maison||94|4|S||500
|||||000001|04/07/2019|Vente|110030,00|5041||B097|LA VILLE|1250|GRAND-CORENT|01|177|B|764|0|1|Maison||90|3|S||522
|||||000001|03/07/2019|Vente|160450,00|||B039|CHARBONNET|1270|COLIGNY|01|108|AH|10|0|1|Maison||110|5|AG||2483
|||||000001|03/07/2019|Vente|160450,00|5515||B039|CHARBONNET|1270|COLIGNY|01|108|AH|126|0|1|Maison||110|5|S||557
|||||000001|03/07/2019|Vente|160450,00|5515||B039|CHARBONNET|1270|COLIGNY|01|108|AH|126|0|1|Maison||110|5|S||557
|||||000001|01/07/2019|Vente|211500,00|||B119|LA GELIERE|1440|VIRIAT|01|451|E|1448|0|1|Maison||108|4|S||1159
|||||000001|01/07/2019|Vente|211500,00|||B119|LA GELIERE|1440|VIRIAT|01|451|E|1448|0|1|Maison||108|4|S||1159
|||||000001|02/07/2019|Vente|180000,00|97||RUE|0605|BRICHEMER|1000|BOURG-EN-BRESSE|01|53|BX|267|0|1|Maison||97|5|S||314
|||||000001|02/07/2019|Vente|216600,00|1||AV|3160|MARECHAL JUIN|1000|BOURG-EN-BRESSE|01|53|CR|68|0|3|Dépendance||0|0|S||1206
|||||000001|02/07/2019|Vente|216600,00|1||AV|3160|MARECHAL JUIN|1000|BOURG-EN-BRESSE|01|53|CR|68|0|3|Dépendance||0|0|S||1206
```

Figure 1. Échantillon du tableau des données DVF (2019-S1).

- Visualisation des données brutes.
- Identification des opérations de nettoyage et filtrage nécessaires (valeurs extrêmes, absurdes, manquantes, doublons, etc).
- Enrichissement du jeu de données à partir de variables dérivées issues des données.
- Encodage des variables pour exploitation par les modèles (normalisation, etc).

Visualisation des données :




Figure 2. Série temporelle des valeurs de ventes.

- Présence de valeurs extrêmes (ventes supérieures à 10 Milliards d'euros).
- Présence de valeurs absurdes (ventes à moins de 1 euro).
- Haut taux de valeurs manquantes dans de nombreuses colonnes.
- Biais introduits par le marché industriel, aux logiques différentes du marché résidentiel.

Filtrage appliqué :

- Sélection des colonnes pertinentes et suppression des lignes contenant des valeurs nulles sur ces variables.
- Réduction au marché privé pour plus de cohérence.
- Troncage des données sur la variable "valeur foncière" (exclusion des ventes < 10 k€ et > 2 M€), ainsi que d'autres variables selon des seuils justifiés.




Figure 3. Série temporelle des valeurs de ventes tronquées.

Enrichissement des données :

- Fréquences d'apparitions des codes postaux : indicateur de l'attractivité locale.
- Prix au m² : variable dérivée pour la visualisation.
- Mois de la vente : variable dérivée pour capter une éventuelle saisonnalité.

Variables explicatives retenues:

→ [Code du département, Superficie du bâtiment, Superficie du terrain, Nombre de pièces, Mois de la vente, Fréquence du code postal, Type de local]

Variable cible :

→ Valeur foncière

Visualisation des données (filtrées) :





Figure 4. Matrice de corrélation (droite), répartition des surfaces en fonction des valeurs de ventes (gauche).

- Existence d'une dynamique entre certaines variables (ex: type de bien et superficie du bâtiment).
- Pas d'information redondante, corrélation faible entre les variables.
- Pas de saisonnalité.
- Absence de linéarité entre les variables et la cible.

Clustering :

- Enrichir les données avec des labels.
- Trouver des clusters interprétables humainement.
- Algorithme non supervisé, **K-Means**.

→ Graphiquement, le nombre idéal de cluster semble être entre 5 et 10 clusters.




Figure 5. Inertie intra-cluster en fonction de k le nombre de clusters.

cluster	Type local	Code departement	Surface terrain		Surface reelle bati		Nombre pieces principales	Frequence CP	Mois	target	
	<lambda>	<lambda>	mean	std	mean	std	mean	mean	mean	mean	std
0	Maison	59	189.97	114.84	67.17	18.63	2.99	702.99	9.77	167178.78	165737.42
1	Maison	44	672.04	158.86	66.65	19.73	2.79	720.88	8.59	215458.29	219343.77
2	Maison	59	361.46	142.30	108.43	22.07	4.71	678.42	9.22	247241.47	180698.31
3	Appartement	59	222.91	159.82	37.71	15.19	1.69	1437.60	7.52	313786.71	311630.94
4	Maison	59	245.79	149.74	74.40	22.12	3.30	771.50	3.24	184222.26	173032.98
5	Maison	59	563.46	228.18	186.03	36.78	6.63	872.71	7.53	425352.67	318606.41
6	Maison	59	373.52	190.89	96.53	25.98	4.32	2394.00	8.01	245813.00	183234.58
7	Maison	59	244.81	197.25	69.68	34.56	3.24	4746.43	7.31	250911.89	220417.04
8	Maison	59	622.07	191.14	110.19	25.57	4.62	776.06	3.13	252657.21	180686.70
9	Maison	33	804.56	132.12	114.98	23.81	4.70	768.35	9.33	264748.58	179212.99

Figure 6. Statistiques des variables dans chaque cluster (k=10).

→ Clusters non humains, mal séparés et centrés autour d'un seul département et d'un seul type d'habitation.

Encodage :

- Normalisation des données numériques.
- Encodage **One-Hot** des données catégorielles (type de bien, code du département).
- Transformation logarithmique de la variable cible.

→ Explosion du nombre de colonnes après **One-Hot**.

Valeur foncière	Mois	Code département
1 M€	9	75
200 k€	1	80
150 k€	5	18
80 k€	8	974
10 k€	11	80




Valeur foncière	Mois	75	80	18	974
13.8	0.8	1	0	0	0
12.2	0	0	1	0	0
11.9	0.4	0	0	1	0
11.3	0.7	0	0	0	1
9.2	1	1	0	0	0

Figure 7. Tableau des données avant encodage (gauche) et après encodage (droite).

Réduction de dimension et PCA :

- Compenser l'explosion du nombre de variables après encodage.
- Réduire le temps de calcul sans perte d'information.



→ ~5 à 6 CP expliquent plus de 80% de la variance.

→ Ce nombre de CP semble être un bon candidat pour la réduction de dimension.

Figure 8. Variance expliquée cumulée par composantes principales (CP).

→ Des structures apparaissent après transformation via PCA mais elles sont difficilement interprétables.

→ Potentiel lien avec les variables catégorielles.




Figure 9. Affichage des trois premières CP après projection des données (colorées par valeurs de vente).

Premier modèle, la Random Forest :

- Nos données sont bruitées, hétérogènes et non-linéaire.
- Modèle simple, peu sensible aux paramètres et efficace sur les données tabulaires.

Random Forest est donc un bon premier candidat pour un premier essai.

Métriques :

- R^2** ☐ Estimation de la qualité du modèle.
- MAE** ☐ Mesure de l'erreur moyenne.
- RMSE** ☐ Mesure de la gravité des erreurs importantes.

Hyperparamètres :

Estimation "*brute force*" (*balayage*) des paramètres idéaux sur un échantillon.

- `n_estimators = 35`
- `max_depth = 55`

Premiers résultats :




Figure 10. Métriques et évaluation de la RF.

- Performances satisfaisantes même sans toucher aux autres hyperparamètres ($R^2 > 0.6$).
- Sous évaluation et sur-estimation de certain biens.

- Résultats décevants, perte des informations en lien avec la variable cible.
- Moins bonne qualité des résultats et plus grandes erreurs.
- Finalement non utilisée par la suite.




Figure 11. Métriques et évaluation de la RF avec PCA.

Multilayer Perceptron (MLP) :

- Nos données sont déjà traitées.
- Modèle plus complexe mais grand potentiel sur des données à relations complexes.

Hyperparamètres :

Nombreux, ils sont estimés à la main pas à pas.


Layer (type)	Output Shape	Param #
dense (Dense)	(None, 512)	53,760
dense_1 (Dense)	(None, 256)	131,328
batch_normalization (BatchNormalization)	(None, 256)	1,024
dropout (Dropout)	(None, 256)	0
dense_2 (Dense)	(None, 1)	257

Figure 12. Modèle MLP finalement utilisé.

Seconds résultats :

Modèle :

- Fonction d'activation : **ReLU**
- Optimiser : **Adam**
- Learning rate : **1e-5 + ReduceLRateOnPlateau**
- Loss : **Huber**



- Moins bonnes métriques qu'avec la RF ($R^2 < 0.5$).
- Toujours une sous évaluation et surestimation de certains biens.
- Les erreurs sont plus grandes.

Figure 13. Métriques, loss et lr_rate du MLP.

Prédiction via moyenne pondérée :

- Les deux modèles sont entraînés sur les mêmes données.
- On calcule la moyenne pondérée des deux prédictions.




Figure 14. Schéma du modèle ($0 > \alpha > 1$).




Figure 15. Métriques du modèle via moyenne.

- Résultats fortement influencés par la pondération sur la prédiction de la RF (ici $\alpha = 0.9$). Les métriques tendent vers les résultats de la RF sans être meilleurs.

Correction de prédiction via résidus :




Figure 16. Schéma du modèle via résidus.

→ Petite amélioration de la qualité du modèle et des métriques. Même si les gains sont petits, la simplicité de la démarche fait qu'ils sont satisfaisants.

- La RF est entraînée sur la variable cible et le MLP est entraîné sur l'écart entre la prédiction de la RF et la variable cible.
- On additionne simplement les deux prédictions, l'une corrigeant l'autre.




Figure 17. Métriques du modèle via résidus.

Enrichissement des features :




Figure 18. Schéma du modèle d'enrichissement.

- La RF et le MLP sont entraînés sur la variable cible.
- On enrichit les données avec la prédiction de la RF.
- Le MLP prédit à partir des données enrichies.

- Les résultats sont encore très proches de ceux de la RF simple, pas d'amélioration nette des métriques.
- D'autres architectures sont à envisager.




Figure 19. Métriques du modèle d'enrichissement.

Conclusion et perspectives :

Les métriques obtenues témoignent de résultats satisfaisants, même avec des modèles relativement simples. L'utilisation de modèles hybrides, qu'ils soient organisés en parallèle ou en série, se révèle prometteuse.

Axes d'améliorations :

- Enrichissement des données :
 - ◆ Intégration de données socio-économiques,
 - ◆ Ajout de coordonnées géographiques précises,
 - ◆ Clustering plus pertinent et mieux adapté,
 - ◆ Extension des variables temporelles aux jours/années (saisonnalité).

- Exploration de modèles alternatifs :
 - ◆ Mise en œuvre d'architectures plus complexes,
 - ◆ Optimisation approfondie des hyperparamètres,
 - ◆ Approfondissement des méthodes hybrides.

Autres pistes d'analyse :

- Recherche d'anomalies dans les transactions.
- Évaluation de la santé du marché immobilier.

Bibliographie :

- **DGFiP (Direction Générale des Finances Publiques).** *Demandes de valeurs foncières.* (2019–2024). <https://www.data.gouv.fr/fr/datasets/demandes-de-valeurs-foncieres>
- **Zhou, Z.-H.** (2012). *Ensemble Methods: Foundations and Algorithms.* CRC Press.
- **Scikit-learn Developers.** (2024). *Scikit-learn Documentation.* <https://scikit-learn.org>
- **TensorFlow Developers.** (2024). *Keras Guide.* <https://www.tensorflow.org/guide?hl=fr>

Annexes :




Figure 2. Distribution des valeurs de vente.




Figure 1. Hotmap du prix/m² moyen par départements en France.




Figure 3. Score de silhouette en fonction du nombre de clusters.




Figure 5. Visualisation des clusters via PCA.

Echantillon de 500 000 lignes :

Architecture	Layers	Neurons/couche	MAE (€)	RMSE (€)	R ²
MLP (Shrinking)	3	512 -> 256 -> 1	77 756	118 625	0.47
MLP (Shrinking)	3	256 -> 128 -> 1	~91 400	~165 800	~0.42
MLP (Constant)	6	512	~90 700	~166 400	~0.42
resMLP	3	512	~89 900	~163 000	~0.44
resMLP	4	128	~91 700	~167 700	~0.41

Sur toutes les données :

Architecture	Layers	Neurons/couche	MAE (€)	RMSE (€)	R ²
MLP (Shrinking)	3	512 -> 256 -> 1	87 295	156 621	0.48

Figure 4. Résultats des différents essais avec des NN.